

統計學

沈威宇

2026 年 8 月 8 日

目錄

第一章 統計學 (Statistics)	1
第一節 一維數據分析	1
一、眾數 (Mode, Mo)	1
二、中位數 (Median, Me)	1
三、(算術) 平均數 ((Arithmetic) mean)	1
四、加權平均數 (Weighted mean)	1
五、幾何平均數	1
六、百分位數 (Percentile, Percentile score)	1
七、四分位數 (Quantile)	3
八、百分位排名/等級 (Percentile rank)	4
九、全距	4
十、四分位距	4
十一、母體變異數 (Population variance) 和母體標準差 (Population standard deviation)	4
十二、樣本變異數 (Sample variance) 和樣本標準差 (Sample standard deviation)	4
十三、仿射變換	5
十四、標準分數 (Standard score) /Z 分數 (z-score)	5
第二節 二維數據分析	5
一、散布圖	5
二、皮爾森積動差相關係數 (Pearson product-moment correlation coefficient, PPMCC, PCC) /相關係數 (Correlation coefficient)	6
三、判定係數 (Coefficient of determination)	6
四、(線性) 迴歸直線/最適直線	6
第三節 多維資料分析	7
一、迴歸直線	7

第四節	Statistical hypothesis test (統計假說檢定)	8
一、	Terms	8
二、	Steps.	9
第五節	參考文獻	9

第一章 統計學 (Statistics)

第一節 一維數據分析

今有一由小到大排列的實數序列 $\mathbf{X} = (x_1, x_2, \dots, x_n)$ 。

一、眾數 (Mode, Mo)

$\text{Mode}(\mathbf{X})$ ，指 $\mathbf{X}$ 中出現次數最多者。

二、中位數 (Median, Me)

$$\text{Median}(\mathbf{X}) = \begin{cases} x_{\frac{n+1}{2}}, & n \text{ is odd.} \\ \frac{x_{\frac{n}{2}} + x_{\frac{n}{2}+1}}{2}, & n \text{ is even.} \end{cases}$$

三、(算術) 平均數 ((Arithmetic) mean)

$$\mu = \frac{\sum_{i=1}^n x_i}{n}$$

四、加權平均數 (Weighted mean)

令 $(x_1, x_2, \dots, x_n)$ 對應的權數/權重 (weight) 為 $(w_1, w_2, \dots, w_n)$ ，則加權平均數為：

$$\frac{\sum_{i=1}^n x_i w_i}{\sum_{i=1}^n w_i}$$

五、幾何平均數

$$\sqrt[n]{\prod_{i=1}^n x_i}$$

六、百分位數 (Percentile, Percentile score)

令：第 k 百分位數為 P_k ， $m = n \frac{k}{100}$ ， $i = [m]$ ， $j = i + 1$ ， $g = m - i$ ， $h = \frac{k}{100}(n - \alpha - \beta + 1) + \alpha$ ，

$r = (n - 1) \frac{k}{100}$ ， $s = [r] + 1$ ， $t = s + 1$ 。

各種百分位數定義主要分為兩類：

- 包含性定義 (Inclusive definition)：較常用。至少有 $k\%$ 的項 $\leq P_k$ ，且至少有 $(100 - k)\%$ 的項 $\geq P_k$ 。
- 排除性定義 (Exclusive definition)：較少用。至少有 $k\%$ 的項 $< P_k$ ，且至少有 $(100 - k)\%$ 的項 $> P_k$ 。

各種百分位數定義：

- inverted_cdf (method 1 of H & F):

$$P_k = \begin{cases} x_j, & g > 0 \\ x_i, & g = 0 \end{cases}$$

- averaged_inverted_cdf (method 2 of H & F): 離散定義中最常用。

$$P_k = \begin{cases} x_j, & g > 0 \\ \frac{x_i + x_j}{2}, & g = 0 \end{cases}$$

- closest_observation (method 3 of H & F):

$$P_k = x_{\text{RoundHalfToEven}(m)}$$

- interpolated_inverted_cdf (method 4 of H & F):

$$\alpha = 0$$

$$\beta = 1$$

$$P_k = x_h$$

- hazen (method 5 of H & F):

$$\alpha = \frac{1}{2}$$

$$\beta = \frac{1}{2}$$

$$P_k = x_h$$

- weibull (method 6 of H & F): Excel PERCENTILE.EXC 使用其乘以% 為值。

$$\alpha = 0$$

$$\beta = 0$$

$$P_k = x_h$$

- linear (method 7 of H & F): Excel PERCENTILE.INC 使用其乘以% 為值。連續定義中最常用。

$$\alpha = 1$$

$$\beta = 1$$

$$P_k = x_h$$

- median_unbiased (method 8 of H & F):

$$\alpha = \frac{1}{3}$$

$$\beta = \frac{1}{3}$$

$$P_k = x_h$$

- normal_unbiased (method 9 of H & F):

$$\alpha = \frac{3}{8}$$

$$\beta = \frac{3}{8}$$

$$P_k = x_h$$

- lower (NumPy old method):

$$P_k = x_s$$

- higher (NumPy old method):

$$P_k = x_t$$

- nearest (NumPy old method):

$$P_k = x_{\text{RoundHalfToEven}(r)+1}$$

- midpoint (NumPy old method):

$$P_k = \frac{x_s + x_t}{2}$$

七、 四分位數 (Quantile)

與百分位數同有該等各種定義，僅將其中之 100 均改為 4、第 k 四分位數稱 Q_k 、PERCENTILE.INC 改為 QUANTILE.INC、PERCENTILE.EXC 改為 QUANTILE.EXC，並另有列其他定義方法。

- 定義一：先取中位數為 Q_2 ，將序列以中位數為界分為兩半，若 n 為奇數則中位數不包含在兩半，分別取兩半之中位數為 Q_1 、 Q_3 。
- 定義二：先取中位數為 Q_2 ，將序列以中位數為界分為兩半，若 n 為奇數則中位數包含在兩半，分別取兩半之中位數為 Q_1 、 Q_3 。
- 定義三：先取中位數為 Q_2 ，若 n 為偶數則將序列以中位數為界分為兩半，分別取兩半之中位數為 Q_1 、 Q_3 ；若 n 除以 4 的商為 q 且餘數為 1，則 $Q_1 = 0.25x_q + 0.75x_{q+1}$ ； $Q_3 = 0.75x_{3q+1} + 0.25x_{3q+2}$ ；若 n 除以 4 的商為 q 且餘數為 3，則 $Q_1 = 0.75x_{q+1} + 0.25x_{q+2}$ ； $Q_3 = 0.25x_{3q+2} + 0.75x_{3q+3}$ 。

八、 百分位排名/等級 (Percentile rank)

令百分位等級 PR，累積次數 CF 為小於等於感興趣值的項數，次數 F 為於等於感興趣值的項數，CF' 為小於感興趣值的項數。

- 定義一：

$$PR = 100 \frac{CF - 0.5F}{n} = 100 \frac{CF' + 0.5F}{n}$$

- 定義二 (Excel PERCENTRANK.INC 定義)，最常用：

$$PR = 100 \frac{CF'}{n - 1}$$

- 定義三 (Excel PERCENTRANK.EXC 定義)：

$$PR = 100 \frac{CF' + 1}{n + 1}$$

九、 全距

$$R = \max(\mathbf{X}) - \min(\mathbf{X})$$

十、 四分位距

$$Q_3 - Q_1$$

十一、 母體變異數 (Population variance) 和母體標準差 (Population standard deviation)

稱 $x_i - \mu$ 為離均差， $i = 1, 2, \dots, n$ 。母體變異數 σ^2 或 $\text{Var}(X)$ ，母體標準差 σ ：

$$\begin{aligned}\sigma^2 &= \frac{\sum_{i=1}^n (x_i - \mu)^2}{n} \\ &= \frac{\sum_{i=1}^n x_i^2}{n} - \mu^2 \\ \sigma &= \sqrt{\sigma^2}\end{aligned}$$

十二、 樣本變異數 (Sample variance) 和樣本標準差 (Sample standard deviation)

稱 $x_i - \mu$ 為離均差， $i = 1, 2, \dots, n$ 。樣本變異數 s^2 ，樣本標準差 s ：

$$\begin{aligned}s^2 &= \frac{\sum_{i=1}^n (x_i - \mu)^2}{n - 1} \\ &= \frac{\sum_{i=1}^n x_i^2 - n\mu^2}{n - 1} \\ s &= \sqrt{s^2}\end{aligned}$$

十三、 仿射變換

$\mathbf{X}$ 的仿射變換 $\mathbf{Y} = (y_i | y_i = ax_i + b, i = 1, 2, \dots, n)$ ，記作 $\mathbf{Y} = a\mathbf{X} + b$ 。

性質：

$$\mu_{\mathbf{Y}} = a\mu_{\mathbf{X}} + b$$

$$\sigma_{\mathbf{Y}} = |a|\sigma_{\mathbf{X}}$$

$$s_{\mathbf{Y}} = |a|s_{\mathbf{X}}$$

$$\text{Mode}(\mathbf{Y}) = a\text{Mode}(\mathbf{X}) + b.$$

$$\text{Median}(\mathbf{Y}) = a\text{Median}(\mathbf{X}) + b.$$

十四、 標準分數 (Standard score) / Z 分數 (z-score)

$\mathbf{Z}$ ，定義為：

$$\mathbf{Z} = \left\{ z_i | z_i = \frac{x_i - \mu}{\sigma}, i = 1, 2, \dots, n \right\}$$

將數據轉換為標準分數的過程稱標準化 (standardizing or normalizing)。

性質：

$$\mu_{\mathbf{Z}} = 0, \quad \sigma_{\mathbf{Z}} = 1$$

$$\sum_{i=1}^n z_i^2 = n$$

第二節 二維數據分析

今有由小到大排列的實數序列 $\mathbf{X} = (x_1, x_2, \dots, x_n)$ 與 $\mathbf{Y} = (y_1, y_2, \dots, y_n)$ ，標準差分別為 $\sigma_{\mathbf{X}}, \sigma_{\mathbf{Y}}$ ，算術平均數分別為 $\mu_{\mathbf{X}}, \mu_{\mathbf{Y}}$ ，標準分數分別為 $\mathbf{X}' = (x'_i | x'_i = \frac{x_i - \mu_{\mathbf{X}}}{\sigma_{\mathbf{X}}}, i = 1, 2, \dots, n)$ 與 $\mathbf{Y}' = (y'_i | y'_i = \frac{y_i - \mu_{\mathbf{Y}}}{\sigma_{\mathbf{Y}}}, i = 1, 2, \dots, n)$ 。

一、 散布圖

將數據點每個 $(x_i, y_i), i = 1, 2, \dots, n$ 描繪在 xy 平面直角座標平面。

二、皮爾森積動差相關係數 (Pearson product-moment correlation coefficient, PPMCC, PCC) / 相關係數 (Correlation coefficient)

$\mathbf{X}$ 與 $\mathbf{Y}$ 的相關係數記作 $r_{\mathbf{XY}}$ 。定義：

$$r_{\mathbf{XY}} = \frac{\sum_{i=1}^n x'_i y'_i}{n} \quad (\text{標準化積和除以項數})$$
$$S_{\mathbf{XX}} = \sum_{i=1}^n (x_i - \mu_{\mathbf{X}})^2 = \sum_{i=1}^n x_i^2 - n\mu_{\mathbf{X}}^2 = n\sigma_{\mathbf{X}}^2$$
$$S_{\mathbf{YY}} = \sum_{i=1}^n (y_i - \mu_{\mathbf{Y}})^2 = \sum_{i=1}^n y_i^2 - n\mu_{\mathbf{Y}}^2 = n\sigma_{\mathbf{Y}}^2$$
$$S_{\mathbf{XY}} = \sum_{i=1}^n (x_i - \mu_{\mathbf{X}})(y_i - \mu_{\mathbf{Y}}) = \sum_{i=1}^n x_i y_i - n\mu_{\mathbf{X}}\mu_{\mathbf{Y}}$$
$$r_{\mathbf{XY}} = \frac{S_{\mathbf{XY}}}{\sqrt{S_{\mathbf{XX}}S_{\mathbf{YY}}}} \quad (\text{離均差積和除以根號離均差平方和積})$$

性質：

$$-1 \leq r \leq 1, \quad 0 \leq r^2 \leq 1$$

$$r_{\mathbf{XY}} = r_{\mathbf{YX}}$$

相關程度：

- $r = 1$ 稱完全正相關； $r = -1$ 稱完全負相關。
- $r > 0$ 稱正相關； $r < 0$ 稱負相關； $r = 0$ 稱無相關。

仿射變換：

令 $\mathbf{X}' = a\mathbf{X} + b$ 、 $\mathbf{Y}' = a\mathbf{Y} + b$ 。

$$r_{\mathbf{X}'\mathbf{Y}'} = \frac{ac}{|ac|} r_{\mathbf{XY}}$$

三、判定係數 (Coefficient of determination)

指皮爾森積動差相關係數的平方。

四、(線性) 迴歸直線/最適直線

令平方和：

$$D = \sum_{i=1}^n (y_i - (mx_i + k))^2$$

解出使 D 最小 (即 D 為最小平方和) 的 m, k 即得 $\mathbf{L}$ (即最小平方法)。

$\mathbf{X}'$ 與 $\mathbf{Y}'$ 的最適直線 $\mathbf{L}$ ： $mx + k$ 為：

$$y' = r_{\mathbf{X}'\mathbf{Y}'} x'$$

$\mathbf{X}$ 與 $\mathbf{Y}$ 的最適直線為：

$$y - \mu_{\mathbf{Y}} = m(x - \mu_{\mathbf{X}})$$

其中：

$$m = r_{\mathbf{XY}} \cdot \frac{\sigma_{\mathbf{Y}}}{\sigma_{\mathbf{X}}} = \frac{S_{\mathbf{XY}}}{S_{\mathbf{XX}}}$$

第三節 多維資料分析

一、迴歸直線

設有 n 個樣本，每個樣本有 m 個特徵。

令矩陣 $\mathbf{X}$ 是 $n \times (m+1)$ 的矩陣，第一 column 是全為 1 的 column（對應截距項），其餘 column 是特徵 $x_1, x_2, \dots, x_m$ 。

令 $\mathbf{y}$ 是 $n \times 1$ 的 column 向量，表示目標變數。

$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1m} \\ 1 & x_{21} & x_{22} & \cdots & x_{2m} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{nm} \end{pmatrix}$$
$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

迴歸係數 $\mathbf{a}$ 可以用以下公式計算：

$$\mathbf{a} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

得到迴歸方程式：

$$y = (1, x_1, x_2, \dots, x_m) \mathbf{a}$$

Proof.

最小平方方法的目標是找到一組係數 $\mathbf{a}$ ，使得實際值 $\mathbf{y}$ 與預測值 $\mathbf{Xa}$ 之間的平方差和最小，即最小化以下目標函數：

$$J(\mathbf{a}) = \sum_{i=1}^n (y_i - \mathbf{X}_i \mathbf{a})^2$$

其中， $\mathbf{X}_i$ 是 $\mathbf{X}$ 的第 i row。寫成矩陣形式：

$$J(\mathbf{a}) = (\mathbf{y} - \mathbf{Xa})^T (\mathbf{y} - \mathbf{Xa})$$

展開：

$$J(\mathbf{a}) = \mathbf{y}^T \mathbf{y} - \mathbf{y}^T \mathbf{Xa} - \mathbf{a}^T \mathbf{X}^T \mathbf{y} + \mathbf{a}^T \mathbf{X}^T \mathbf{Xa}$$

因純量的轉置為其自身，所以：

$$\mathbf{y}^T \mathbf{Xa} = \mathbf{a}^T \mathbf{X}^T \mathbf{y}$$

即：

$$J(\mathbf{a}) = \mathbf{y}^T \mathbf{y} - 2\mathbf{y}^T \mathbf{Xa} + \mathbf{a}^T \mathbf{X}^T \mathbf{Xa}$$

要最小化 $J(\mathbf{a})$ ，我們對 $\mathbf{a}$ 求導數並令其為零：

$$\frac{\partial J(\mathbf{a})}{\partial \mathbf{a}} = -2\mathbf{y}^T \mathbf{X} + \mathbf{X}^T \mathbf{Xa} = 0$$

整理後得到：

$$\mathbf{X}^T \mathbf{X} \mathbf{a} = \mathbf{X}^T \mathbf{y}$$

假設 $\mathbf{X}^T \mathbf{X}$ 是可逆的，我們可以兩邊同時乘以 $(\mathbf{X}^T \mathbf{X})^{-1}$ ：

$$\mathbf{a} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

□

第四節 Statistical hypothesis test (統計假說檢定)

A statistical hypothesis test is a method of statistical inference used to decide whether the data sufficiently supports a particular hypothesis.

一、Terms

- Statistical hypothesis (統計假說): A statement about the parameters describing a population (not a sample).
- Test statistic (統計量) T : A value calculated from a sample without any unknown parameters, often to summarize the sample for comparison purposes.
- Simple hypothesis (簡單假說): Any hypothesis which specifies the population distribution completely.
- Null hypothesis (虛無假說) H_0 : The claim that the effect being studied does not exist.
- Positive data (陽性數據): Data that enable the investigator to reject a null hypothesis.
- Alternative hypothesis (對立假說) H_1 : One of the proposed propositions in the hypothesis test.
- Region of rejection (拒絕域) or Critical region: The set of values of the test statistic for which the null hypothesis is rejected.
- Power of test (檢定力) $1 - \beta$: In the case of a simple hypothesis test with two hypotheses, the power of the test is the probability that the test correctly rejects the null hypothesis H_0 when the alternative hypothesis H_1 is true.
- Size or False positive rate (偽陽性率): For simple hypotheses, this is the test's probability of incorrectly rejecting the null hypothesis.
- p-value (p 值) p : The probability of obtaining a result at least as extreme, given that the null hypothesis is true.
- Significance level (顯著水準) α : The probability of the study rejecting the null hypothesis, given that the null hypothesis is true. The result is statistically significant, by the standards of the study, when $p < \alpha$.
- Most powerful test: For a given size or significance level, the test with the greatest power (probability of rejection) for a given value of the parameter(s) being tested, contained in the alternative hypothesis.

- Uniformly most powerful test (UMP): The hypothesis test which has the greatest power $1 - \beta$ among all possible tests of a given size.

二、 Steps

The typical steps involved in performing a frequentist hypothesis test in practice are:

1. Define a hypothesis (claim which is testable using data).
2. Select a relevant statistical test with associated test statistic T .
3. Derive the distribution of the test statistic under the null hypothesis from the assumptions.
4. Select a significance level α .
5. Compute from the observations the observed value t_{obs} of the test statistic T .
6. Decide to either reject the null hypothesis in favor of the alternative hypothesis or not reject it. Reject the null hypothesis H_0 if the observed value t_{obs} is in the critical region, and not reject the null hypothesis otherwise.

第五節 參考文獻

- R. J. Hyndman and Y. Fan, “Sample quantiles in statistical packages,” The American Statistician, 50(4), pp. 361-365, 1996.
- Numpy. numpy.percentile. <https://numpy.org/doc/stable/reference/generated/numpy.percentile>
- Wikipedia. <https://wikipedia.org>.