# 統計學

沈威宇

November 8, 2026

# Contents


Chapter 1　統計學（Statistics）　1

1　一維數據分析　1

I　眾數（Mode, Mo）　1

II　中位數（Median, Me）　1

III　（算術）平均數（(Arithmetic) mean）　1

IV　加權平均數（Weighted mean）　1

V　幾何平均數　1

VI　百分位數（Percentile, Percentile score）　2

VII　四分位數（Quantile）　3

VIII　百分位排名/等級（Percentile rank）　4

IX　全距　4

X　四分位距　4

XI　母體變異數 (Population variance) 和母體標準差 (Population standard deviation）　4

XII　樣本變異數（Sample variance）和樣本標準差（Sample standard deviation）　5

XIII　仿射變換　5

XIV　標準分數（Standard score）/Z 分數（z-score）　5

2　二維數據分析　5

I　散布圖　6

II　皮爾森積動差相關係數（Pearson product-moment correlation coefficient, PPMCC, PCC）/相關係數（Correlation coefficient）　6

III　判定係數（Coefficient of determination）　6

IV （線性）迴歸直線/最適直線 . . . . . 6

3 多維資料分析 . . . . . 7

I 迴歸直線 . . . . . 7

4 Statistical hypothesis test (統計假說檢定) . . . . . 8

I Terms . . . . . 8

II Steps . . . . . 9

5 參考文獻 . . . . . 9

# Chapter 1　統計學（Statistics）

## 1　一維數據分析

今有一由小到大排列的實數序列 $\mathbf{X} = (x_1, x_2, \dots, x_n)$。

### I　眾數（Mode, Mo）

Mode($\mathbf{X}$)，指 $\mathbf{X}$ 中出現次數最多者。

### II　中位數（Median, Me）

$$\text{Median}(\mathbf{X}) = \begin{cases} x_{\frac{n+1}{2}}, & n \text{ is odd.} \\ \dfrac{x_{\frac{n}{2}} + x_{\frac{n}{2}+1}}{2}, & n \text{ is even.} \end{cases}$$

### III　（算術）平均數（(Arithmetic) mean）

$$\mu = \frac{\sum_{i=1}^{n} x_i}{n}$$

### IV　加權平均數（Weighted mean）

令 $(x_1, x_2, \dots, x_n)$ 對應的權數/權重（weight）為 $(w_1, w_2, \dots, w_n)$，則加權平均數為：

$$\frac{\sum_{i=1}^{n} x_i w_i}{\sum_{i=1}^{n} w_i}$$

### V　幾何平均數

$$\sqrt[n]{\prod_{i=1}^{n} x_i}$$

## VI　百分位數（Percentile, Percentile score）

令：第 $k$ 百分位數為 $P_k$，$m = n\frac{k}{100}$，$i = \lfloor m \rfloor$，$j = i+1$，$g = m-i$，$h = \frac{k}{100}(n-\alpha-\beta+1)+\alpha$，$r = (n-1)\frac{k}{100}$，$s = \lfloor r \rfloor + 1$，$t = s+1$。
各種百分位數定義主要分為兩類：

- 包含性定義(Inclusive definition)：較常用。至少有 $k$% 的項 $\leq P_k$，且至少有 $(100-k)\%$ 的項 $\geq P_k$。
- 排他性定義(Exclusive definition)：較少用。至少有 $k\%$ 的項 $< P_k$，且至少有 $(100-k)\%$ 的項 $> P_k$。

各種百分位數定義：

- inverted_ cdf (method 1 of H & F):

$$P_k = \begin{cases} x_j, g > 0 \\ x_i, g = 0 \end{cases}$$

- averaged_ inverted_ cdf (method 2 of H & F): 離散定義中最常用。

$$P_k = \begin{cases} x_j, g > 0 \\ \frac{x_i + x_j}{2}, g = 0 \end{cases}$$

- closest_ observation (method 3 of H & F):

$$P_k = x_{\text{RoundHalfToEven}(m)}$$

- interpolated_ inverted_ cdf (method 4 of H & F):

$$\alpha = 0$$
$$\beta = 1$$
$$P_k = x_h$$

- hazen (method 5 of H & F):

$$\alpha = \frac{1}{2}$$
$$\beta = \frac{1}{2}$$
$$P_k = x_h$$

- weibull (method 6 of H & F): Excel PERCENTILE.EXC 使用其乘以% 為值。

$$\alpha = 0$$
$$\beta = 0$$
$$P_k = x_h$$

- linear (method 7 of H & F): Excel PERCENTILE.INC 使用其乘以% 為值。連續定義中最常用。

$$\alpha = 1$$
$$\beta = 1$$
$$P_k = x_h$$

- median_ unbiased (method 8 of H & F):

$$\alpha = \frac{1}{3}$$
$$\beta = \frac{1}{3}$$
$$P_k = x_h$$

- normal_ unbiased (method 9 of H & F):

$$\alpha = \frac{3}{8}$$
$$\beta = \frac{3}{8}$$
$$P_k = x_h$$

- lower (NumPy old method):

$$P_k = x_s$$

- higher (NumPy old method):

$$P_k = x_t$$

- nearest (NumPy old method):

$$P_k = x_{\text{RoundHalfToEven}(r)+1}$$

- midpoint (NumPy old method):

$$P_k = \frac{x_s + x_t}{2}$$

## VII　四分位數（Quantile）

與百分位數同有該等各種定義，僅將其中之 100 均改為 4、第 $k$ 四分位數稱 $Q_k$、PERCENTILE.INC 改為 QUANTILE.INC、PERCENTILE.EXC 改為 QUANTILE.EXC，並另有下列其他定義方法。

- 定義一：先取中位數為 $Q_2$，將序列以中位數為界分為兩半，若 $n$ 為奇數則中位數不包含在兩半，分別取兩半之中位數為 $Q_1$、$Q_3$。

- 定義二：先取中位數為 $Q_2$，將序列以中位數為界分為兩半，若 $n$ 為奇數則中位數包含在兩半，分別取兩半之中位數為 $Q_1$、$Q_3$。
- 定義三：先取中位數為 $Q_2$，若 $n$ 為偶數則將序列以中位數為界分為兩半，分別取兩半之中位數為 $Q_1$、$Q_3$；若 $n$ 除以 4 的商為 $q$ 且餘數為 1，則 $Q_1 = 0.25x_q + 0.75x_{q+1}$；$Q_3 = 0.75x_{3q+1} + 0.25x_{3q+2}$；若 $n$ 除以 4 的商為 $q$ 且餘數為 3，則 $Q_1 = 0.75x_{q+1} + 0.25x_{q+2}$；$Q_3 = 0.25x_{3q+2} + 0.75x_{3q+3}$。

## VIII 百分位排名/等級（Percentile rank）

令百分位等級 PR，累積次數 CF 為小於等於感興趣值的項數，次數 F 為於等於感興趣值的項數，CF′ 為小於感興趣值的項數。

- 定義一：

$$\mathrm{PR} = 100\frac{\mathrm{CF} - 0.5\mathrm{F}}{n} = 100\frac{\mathrm{CF}' + 0.5\mathrm{F}}{n}$$

- 定義二（Excel PERCENTRANK.INC 定義），最常用：

$$\mathrm{PR} = 100\frac{CF'}{n-1}$$

- 定義三（Excel PERCENTRANK.EXC 定義）：

$$\mathrm{PR} = 100\frac{CF'+1}{n+1}$$

## IX 全距

$$R = \max(\mathbf{X}) - \min(\mathbf{X})$$

## X 四分位距

$$Q_3 - Q_1$$

## XI 母體變異數（Population variance）和母體標準差（Population standard deviation）

稱 $x_i - \mu$ 為離均差，$i = 1, 2, \ldots, n$。母體變異數 $\sigma^2$ 或 $\mathrm{Var}(X)$，母體標準差 $\sigma$：

$$\begin{aligned}\sigma^2 &= \frac{\sum_{i=1}^{n}(x_i - \mu)^2}{n} \\ &= \frac{\sum_{i=1}^{n} {x_i}^2}{n} - \mu^2 \\ \sigma &= \sqrt{\sigma^2}\end{aligned}$$

### XII　樣本變異數（Sample variance）和樣本標準差（Sample standard deviation）

稱 $x_i - \mu$ 為離均差，$i = 1, 2, \dots, n$。樣本變異數 $s^2$，樣本標準差 $s$：

$$\begin{aligned} s^2 &= \frac{\sum_{i=1}^{n}(x_i - \mu)^2}{n-1} \\ &= \frac{\sum_{i=1}^{n} {x_i}^2 - n\mu^2}{n-1} \\ s &= \sqrt{s^2} \end{aligned}$$

### XIII　仿射變換

**X** 的仿射變換 $\mathbf{Y} = (y_i | y_i = ax_i + b, i = 1, 2, \dots, n)$，記作 $\mathbf{Y} = a\mathbf{X} + b$。

性質：

$$\mu_{\mathbf{Y}} = a\mu_{\mathbf{X}} + b$$

$$\sigma_{\mathbf{Y}} = |a|\sigma_{\mathbf{X}}$$

$$s_{\mathbf{Y}} = |a| s_{\mathbf{X}}$$

$$\text{Mode}(\mathbf{Y}) = a\text{Mode}(\mathbf{X}) + b.$$

$$\text{Median}(\mathbf{Y}) = a\text{Median}(\mathbf{X}) + b.$$

### XIV　標準分數（Standard score）/Z 分數（z-score）

**Z**，定義為：

$$\mathbf{Z} = \left\{ z_i | z_i = \frac{x_i - \mu}{\sigma}, \quad i = 1, 2, \dots, n \right\}$$

將數據轉換為標準分數的過程稱標準化（standardizing or normalizing）。

性質：

$$\mu_{\mathbf{Z}} = 0, \quad \sigma_{\mathbf{Z}} = 1$$

$$\sum_{i=1}^{n} {z_i}^2 = n$$

## 2　二維數據分析

今有由小到大排列的實數序列 $\mathbf{X} = (x_1, x_2, \dots, x_n)$ 與 $\mathbf{Y} = (y_1, y_2, \dots, y_n)$，標準差分別為 $\sigma_{\mathbf{X}}, \sigma_{\mathbf{Y}}$，算術平均數分別為 $\mu_{\mathbf{X}}, \mu_{\mathbf{Y}}$，標準分數分別為 $\mathbf{X}' = \left( x_i' | x_i' = \frac{x_i - \mu_{\mathbf{X}}}{\sigma_{\mathbf{X}}}, i = 1, 2, \dots, n \right)$ 與 $\mathbf{Y}' = \left( y_i' | y_i' = \frac{y_i - \mu_{\mathbf{Y}}}{\sigma_{\mathbf{Y}}}, i = 1, 2, \dots, n \right)$。

## I 散布圖

將數據點每個 $(x_i, y_i), i = 1, 2, \ldots, n$ 描繪在 $xy$ 平面直角座標平面。

## II 皮爾森積動差相關係數（Pearson product-moment correlation coefficient, PPMCC, PCC）/相關係數（Correlation coefficient）

**X** 與 **Y** 的相關係數記作 $r_{\mathbf{XY}}$。定義：

$$r_{\mathbf{XY}} = \frac{\sum_{i=1}^{n} x_i' y_i'}{n} \quad \text{（標準化積和除以項數）}$$

$$S_{\mathbf{XX}} = \sum_{i=1}^{n} (x_i - \mu_{\mathbf{X}})^2 = \sum_{i=1}^{n} x_i^2 - n{\mu_{\mathbf{X}}}^2 = n{\sigma_{\mathbf{X}}}^2$$

$$S_{\mathbf{YY}} = \sum_{i=1}^{n} (y_i - \mu_{\mathbf{Y}})^2 = \sum_{i=1}^{n} y_i^2 - n{\mu_{\mathbf{Y}}}^2 = n{\sigma_{\mathbf{Y}}}^2$$

$$S_{\mathbf{XY}} = \sum_{i=1}^{n} (x_i - \mu_{\mathbf{X}})(y_i - \mu_{\mathbf{Y}}) = \sum_{i=1}^{n} x_i y_i - n\mu_{\mathbf{X}}\mu_{\mathbf{Y}}$$

$$r_{\mathbf{XY}} = \frac{S_{\mathbf{XY}}}{\sqrt{S_{\mathbf{XX}} S_{\mathbf{YY}}}} \quad \text{（離均差積和除以根號離均差平方和積）}$$

性質：

$$-1 \le r \le 1, \quad 0 \le r^2 \le 1$$

$$r_{\mathbf{XY}} = r_{\mathbf{YX}}$$

相關程度：

- $r = 1$ 稱完全正相關；$r = -1$ 稱完全負相關。
- $r > 0$ 稱正相關；$r < 0$ 稱負相關；$r = 0$ 稱無無相關。

仿射變換：
令 $\mathbf{X}' = a\mathbf{X} + b$、$\mathbf{Y}' = a\mathbf{Y} + b$。

$$r_{\mathbf{X}'\mathbf{Y}'} = \frac{ac}{|ac|} r_{\mathbf{XY}}$$

## III 判定係數（Coefficient of determination）

指皮爾森積動差相關係數的平方。

## IV （線性）迴歸直線/最適直線

令平方和：

$$D = \sum_{i=1}^{n} \left(y_i - (mx_i + k)\right)^2$$

解出使 $D$ 最小（即 $D$ 為最小平方和）的 $m, k$ 即得 **L**（即最小平方法）。
$\mathbf{X}'$ 與 $\mathbf{Y}'$ 的最適直線 **L**： $mx + k$ 為：

$$y' = r_{\mathbf{X}'\mathbf{Y}'} x'$$

**X** 與 **Y** 的最適直線為：

$$y - \mu_{\mathbf{Y}} = m(x - \mu_{\mathbf{X}})$$

其中：

$$m = r_{\mathbf{XY}} \cdot \frac{\sigma_{\mathbf{Y}}}{\sigma_{\mathbf{X}}} = \frac{S_{\mathbf{XY}}}{S_{\mathbf{XX}}}$$

# 3 多維資料分析

## I 迴歸直線

設有 $n$ 個樣本，每個樣本有 $m$ 個特徵。
令矩陣 **X** 是 $n \times (m+1)$ 的矩陣，第一 column 是全為 1 的 column （對應截距項），其餘 column 是特徵 $x_1, x_2, \dots, x_m$。
令 **y** 是 $n \times 1$ 的 column 向量，表示目標變數。

$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1m} \\ 1 & x_{21} & x_{22} & \cdots & x_{2m} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{nm} \end{pmatrix}$$

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

迴歸係數 **a** 可以用以下公式計算：

$$\mathbf{a} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$$

得到迴歸方程式：

$$y = (1, x_1, x_2, \dots, x_m)\mathbf{a}$$

*Proof.*
最小平方法的目標是找到一組係數 **a**，使得實際值 **y** 與預測值 **Xa** 之間的平方差和最小，即最小化以下目標函數：

$$J(\mathbf{a}) = \sum_{i=1}^{n} (y_i - \mathbf{X}_i\mathbf{a})^2$$

其中，$\mathbf{X}_i$ 是 **X** 的第 $i$ row。寫成矩陣形式：

$$J(\mathbf{a}) = (\mathbf{y} - \mathbf{X}\mathbf{a})^T(\mathbf{y} - \mathbf{X}\mathbf{a})$$

展開：

$$J(\mathbf{a}) = \mathbf{y}^T\mathbf{y} - \mathbf{y}^T\mathbf{X}\mathbf{a} - \mathbf{a}^T\mathbf{X}^T\mathbf{y} + \mathbf{a}^T\mathbf{X}^T\mathbf{X}\mathbf{a}$$

因純量的轉置為其自身，所以：

$$\mathbf{y}^T\mathbf{X}\mathbf{a} = \mathbf{a}^T\mathbf{X}^T\mathbf{y}$$

即：

$$J(\mathbf{a}) = \mathbf{y}^T\mathbf{y} - 2\mathbf{y}^T\mathbf{X}\mathbf{a} + \mathbf{a}^T\mathbf{X}^T\mathbf{X}\mathbf{a}$$

要最小化 $J(\mathbf{a})$，我們對 $\mathbf{a}$ 求導數並令其為零：

$$\frac{\partial J(\mathbf{a})}{\partial \mathbf{a}} = -2\mathbf{y}^T\mathbf{X} + \mathbf{X}^T\mathbf{X}\mathbf{a} = 0$$

整理後得到：

$$\mathbf{X}^T\mathbf{X}\mathbf{a} = \mathbf{X}^T\mathbf{y}$$

假設 $\mathbf{X}^T\mathbf{X}$ 是可逆的，我們可以兩邊同時乘以 $(\mathbf{X}^T\mathbf{X})^{-1}$：

$$\mathbf{a} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$$

□

# 4 Statistical hypothesis test (統計假說檢定)

A statistical hypothesis test is a method of statistical inference used to decide whether the data sufficiently supports a particular hypothesis.

## I Terms

- Statistical hypothesis (統計假說): A statement about the parameters describing a population (not a sample).
- Test statistic (統計量) $T$: A value calculated from a sample without any unknown parameters, often to summarize the sample for comparison purposes.
- Simple hypothesis (簡單假說): Any hypothesis which specifies the population distribution completely.
- Null hypothesis (虛無假說) $H_0$: The claim that the effect being studied does not exist.
- Positive data (陽性數據): Data that enable the investigator to reject a null hypothesis.
- Alternative hypothesis (對立假說) $H_1$: One of the proposed propositions in the hypothesis test.
- Region of rejection (拒絕域) or Critical region: The set of values of the test statistic for which the null hypothesis is rejected.

- Power of test (検定力) $1 - \beta$: In the case of a simple hypothesis test with two hypotheses, the power of the test is the probability that the test correctly rejects the null hypothesis $H_0$ when the alternative hypothesis $H_1$ is true.
- Size or False positive rate (偽陽性率); For simple hypotheses, this is the test's probability of incorrectly rejecting the null hypothesis.
- p-value (p 値) $p$: The probability of obtaining a result at least as extreme, given that the null hypothesis is true.
- Significance level (顕著水準) $\alpha$: The probability of the study rejecting the null hypothesis, given that the null hypothesis is true. The result is statistically significant, by the standards of the study, when $p < \alpha$.
- Most powerful test: For a given size or significance level, the test with the greatest power (probability of rejection) for a given value of the parameter(s) being tested, contained in the alternative hypothesis.
- Uniformly most powerful test (UMP): The hypothesis test which has the greatest power $1 - \beta$ among all possible tests of a given size.

### II Steps

The typical steps involved in performing a frequentist hypothesis test in practice are:

1. Define a hypothesis (claim which is testable using data).
2. Select a relevant statistical test with associated test statistic $T$.
3. Derive the distribution of the test statistic under the null hypothesis from the assumptions.
4. Select a significance level $\alpha$.
5. Compute from the observations the observed value $t_{obs}$ of the test statistic $T$.
6. Decide to either reject the null hypothesis in favor of the alternative hypothesis or not reject it. Reject the null hypothesis $H_0$ if the observed value $t_{obs}$ is in the critical region, and not reject the null hypothesis otherwise.

## 5 参考文獻


- R. J. Hyndman and Y. Fan, "Sample quantiles in statistical packages," The American Statistician, 50(4), pp. 361-365, 1996.
- Numpy. numpy.percentile. https://numpy.org/doc/stable/reference/generated/numpy.perc
- Wikipedia. https://wikipedia.org.